`SignoriniPostprocessing.jl`

Signorini escalar en forma mixta y postproceso de Muga–Rojas–Vega

Noviembre 2026

1. Problema y método

Dados f y u_D, con $\partial\Omega = \Gamma_D \cup \Gamma_S$, se busca (σ, u) tal que (Wang–Hu–Zhou [2])

$$\sigma - \nabla u = 0, \quad \operatorname{div}\sigma + f = 0 \text{ en } \Omega, \qquad u = u_D \text{ en } \Gamma_D, \qquad u \geq 0, \;\; \sigma\cdot n \geq 0, \;\; u\,(\sigma\cdot n) = 0 \text{ en } \Gamma_S.$$

Opcionalmente: un término de reacción $-\operatorname{div}\sigma + c\,u = f$ (Führer–Heuer–Stephan [4]), un obstáculo $u \geq \chi$, $(u-\chi)\,\sigma\cdot n = 0$ en Γ_S, una frontera de Neumann Γ_N con $\sigma\cdot n = g$ (Bartels–Gudi–Kaltenbach [5]), y Γ_D puede faltar.

Discretización. $\Sigma_h \times Q_h = \mathrm{BDM}_{k+1} \times \mathrm{P}_k$ (discontinuo), $k \geq 0$. Sin multiplicador de Lagrange: σ_h se busca en el cono convexo

$$K_h = \{\tau \in \Sigma_h : \text{ todos los coeficientes de Bernstein de } \tau\cdot n|_F \text{ son } \geq 0, \; \forall F \subset \Gamma_S\},$$

y $(\sigma_h, u_h) \in K_h \times Q_h$ resuelve la desigualdad variacional

$$\begin{aligned} (\sigma_h, \tau - \sigma_h) + (u_h, \operatorname{div}(\tau - \sigma_h)) &\geq \langle u_D, (\tau-\sigma_h)\cdot n\rangle_{\Gamma_D} && \forall\, \tau \in K_h, \\ (\operatorname{div}\sigma_h, v) &= -(f, v) && \forall\, v \in Q_h. \end{aligned}$$

Con los datos opcionales se agrega $-(c\,u_h, v)$ a la segunda ecuación y $\langle \chi, (\tau-\sigma_h)\cdot n\rangle_{\Gamma_S}$ al lado derecho de la primera, y $\sigma_h\cdot n = g$ se impone de forma esencial en Γ_N. Por la propiedad de envolvente convexa, K_h garantiza $\sigma_h\cdot n \geq 0$ en todo punto de Γ_S; es exacto para $k=0$ (trazas lineales) y conservativo para $k \geq 1$.

Active set. En cada faceta $F \subset \Gamma_S$ los $k+2$ grados de libertad de $\sigma_h\cdot n|_F$ se reparametrizan por sus coeficientes de Bernstein $c_{F,i}$ ($x = T\tilde{x}$). Cada $c_{F,i}$ está *en contacto* (libre) o *separado* ($c_{F,i} = 0$). Con $\mu_{F,i}$ el multiplicador algebraico de $c_{F,i} \geq 0$ (residuo del sistema completo, análogo discreto de $\int_F u\,B_i$), la actualización es

$$\text{contacto} \to \text{separado si } c_{F,i} < -\mathrm{tol}\,\|c\|_\infty, \qquad \text{separado} \to \text{contacto si } \mu_{F,i} < -\mathrm{tol}\,\|\mu\|_\infty,$$

hasta que el conjunto no cambia. La matriz se ensambla una vez; cada iteración solo cambia T.

Postproceso (§3.1 de [1]). Con $p = k+1$ y $q_h = -\sigma_h$ (el paper usa $q = -\nabla u$), en cada K se resuelve: hallar $(\varepsilon_K, \nu_K) \in V^{p+2}_{\star,K} \times V^{p+1}_K$ tal que

$$\begin{aligned} (\nabla\varepsilon_K, \nabla v)_K + (\nabla\nu_K, \nabla v)_K &= -(q_h, \nabla v)_K && \forall\, v \in V^{p+2}_{\star,K}, \\ (\nabla w, \nabla\varepsilon_K)_K &= 0 && \forall\, w \in V^{p+1}_{\star,K}, \\ (\nu_K, 1)_K &= (u_h, 1)_K. \end{aligned}$$

Las medias nulas se imponen con dos multiplicadores escalares por elemento; cada sistema local se resuelve en forma densa, sin ensamblaje global.

2. Estructura

Archivo	Contenido
`src/BernsteinTrace.jl`	base de Bernstein en facetas (`bernstein_transform`, `facet_bernstein_coeffs`)
`src/ScalarSignorini.jl`	cono K_h, transformación T, multiplicadores, `solve_scalar_signorini`
`src/ResidualMinimization.jl`	sistemas locales (3.2), `residual_minimization_postprocess`
`src/StenbergPostprocess.jl`	postproceso (2.10), `stenberg_postprocess` ($= \nu_h$, Prop. 3.1)
`src/Estimators.jl`	estimador a posteriori (sección 5), `contact_estimator`
`test/manufactured.jl`	solución exacta, mallas (`LEVELS`), normas
`studies/`	estudios: `convergence`, `aposteriori`, `adaptivity`, `references` (ejemplos de [4, 5]), `estimators`; CSV en `results/csv/`, PDF en `results/pdf/`

3. Uso

```
using SignoriniPostprocessing, Gridap

model  = simplexify(CartesianDiscreteModel((-0.5, 0.5, 0.0, 1.0), (32, 32)))
labels = get_face_labeling(model)
add_tag_from_tags!(labels, "GammaS", ["tag_5"])                    # y = 0
add_tag_from_tags!(labels, "GammaD", ["tag_6", "tag_7", "tag_8"])  # resto

f(x)  = 1.0
uD(x) = x[2]

k   = 1
sol = solve_scalar_signorini(model; k, f, uD, tag_D = "GammaD", tag_S = "GammaS")
sol.converged || error("el active set no convergió")

pp = residual_minimization_postprocess(model, -sol.σh, sol.uh, k + 1)
pp.νh    # postproceso, P_{k+2}
pp.εh    # representante del residuo, P_{k+3}, media nula por elemento

est = contact_estimator(model, sol, pp.νh, pp.εh; k, uD, tag_D = "GammaD")
est.η2   # η_K² por elemento (para marcar);  est.parts: cada término sumado
```

`solve_scalar_signorini`. Obligatorios: `model`, `k`, `f`, `tag_S`. Datos opcionales: `uD`, `tag_D` (Dirichlet), `reaction` $= c \geq 0$, `χ` (obstáculo, función de `x`), `tag_N` y `gN` (Neumann; `gN` es un campo vectorial cuya traza normal es g). Opcionales: `qdegree` $= 2k + 6$ (cuadratura), `maxit` $= 100$, `tol` $= 10^{-10}$ (guarda relativa de redondeo del active set), `init_contact` $=$ `false` (estado inicial: todo separado). Devuelve un `NamedTuple` con, entre otros: `σh`, `uh` (`FEFunction`), `Ω`, `dΩ`, `ΓS`, `nS`, `state` (por faceta, `true` $=$ contacto), `c` y `μ` (coeficientes de Bernstein de $\sigma_h \cdot n$ y multiplicadores por faceta), `it`, `converged`, `ndofs`.

`residual_minimization_postprocess`. Argumentos `(model, qh, uh, p; qdegree)`: `qh` es el flujo en la convención del paper ($q_h \approx -\nabla u$), `p` el grado BDM. Devuelve `νh`, `εh` y sus espacios `Vν`, `Vε`. Sirve para cualquier par mixto $\mathrm{BDM}_p \times \mathrm{P}_{p-1}$, no solo para Signorini.

4. Cómo resolver otro problema

Malla. Cualquier `DiscreteModel` 2D de triángulos con facetas rectas, por ejemplo

```
model = simplexify(CartesianDiscreteModel((a, b, c, d), (nx, ny)))
model = GmshDiscreteModel("malla.msh")      # requiere GridapGmsh en el entorno
```

Γ_D y Γ_S se pasan como nombres de etiqueta (`add_tag_from_tags!` o grupos físicos de Gmsh). Si Γ_D, Γ_S, Γ_N no vienen como etiquetas, se crean por la posición del punto medio de cada faceta (`tag_boundary_facets!` en `studies/references/reference_examples.jl`). Las etiquetas pasan a las mallas refinadas. Requisitos: Γ_D, Γ_S, Γ_N disjuntos, y el problema bien planteado ($|\Gamma_D| > 0$ o $c > 0$). Las facetas de $\partial\Omega$ sin etiqueta quedan con $u = 0$ (condición natural de la forma mixta). Mallas armadas a mano: los vértices de cada triángulo en orden creciente (`Oriented()`), como exigen los espacios BDM de Gridap.

Datos. `f`, `uD`, `χ` son funciones de un punto `x` (`x[1]`, `x[2]`). La convención es $\sigma = \nabla u$ con $u \geq \chi$, $\sigma \cdot n \geq 0$ en Γ_S.

Parámetros. El grado `k` (probado para $k = 0, \ldots, 3$). Si f o u_D varían fuertemente, aumentar `qdegree`. Si el active set no converge, revisar `it` y `ncontact` antes de aumentar `maxit`.

Coeficientes de la EDP. Hay reacción constante (`reaction`); la difusión es unitaria. Para $-\operatorname{div}(\kappa\nabla u) = f$ con $\sigma = \kappa\nabla u$ habría que cambiar (σ, τ) por $(\kappa^{-1}\sigma, \tau)$ en la forma `a` de `ScalarSignorini.jl` y $(\nabla\cdot, \nabla\cdot)_K$ por $(\kappa\nabla\cdot, \nabla\cdot)_K$ en `Aεε`, `Bεν` de `ResidualMinimization.jl`; no está implementado ni verificado.

Tests y estudios. Todo está en `test/manufactured.jl`: la solución exacta en las líneas 48–55 (`uex`, `σex` $= \nabla u$, `fex` $= -\Delta u$, consistentes entre sí y cumpliendo Signorini en Γ_S), el dominio y las etiquetas en `square_model`, y las mallas por grado en `LEVELS` (línea 71). Las cotas de tasa de los tests suponen una solución suficientemente regular.

5. Estimador a posteriori

`contact_estimator` calcula, con $q_h = -\sigma_h$ y $\beta_F = \sum_{i \text{ en contacto}} B_i$ (partición de la unidad de Bernstein restringida a los coeficientes de $\sigma_h \cdot n|_F$ que el active set dejó en contacto),

$$\eta_K^2 = \|\nabla\varepsilon_K\|_K^2 + \|\sigma_h - \nabla\nu_h\|_K^2 + \tfrac{1}{2}\sum_{F\subset\partial K\setminus\partial\Omega} h_F^{-1}\|[\![\nu_h]\!]\|_F^2 + \sum_{F\subset\partial K\cap\Gamma_D} h_F^{-1}\|u_D - \nu_h\|_F^2$$
$$+ \sum_{F\subset\partial K\cap\Gamma_S}\Big(h_F^{-1}\|\beta_F^{1/2}(\nu_h - \chi)\|_F^2 + h_F^{-1}\|(1-\beta_F)^{1/2}\min(\nu_h - \chi, 0)\|_F^2\Big).$$

La primera línea es el estimador mejorado (3.9) de [1]. En Γ_S la traza de u es desconocida y el término de Dirichlet se reemplaza por: $u = \chi$ donde hay contacto y solo la violación de $u \geq \chi$ donde hay separación. No usa la ecuación de momentum (no hay residuo $f - \operatorname{div} q_h$). No hace falta un término para el signo de $\sigma_h \cdot n$: el cono da $\sigma_h \cdot n \geq 0$ en todo punto. En Γ_N no hay término. La confiabilidad para la desigualdad variacional no está demostrada; aun para el problema lineal, el Teorema 3.9 de [1] la da bajo la hipótesis de saturación (Hipótesis 3.5), con constante $1/(1-\delta)$.

Elección del término de contacto. Sobre las mismas soluciones, con f constante (`contact_terms.jl` en `studies/estimators/`), se compararon variantes del término en Γ_S: sin término; clasificación por faceta completa (en vez de β_F); clasificación por $\sigma_h \cdot n > 0$; agregar $|\langle \sigma_h \cdot n, \nu_h - \chi \rangle_F|$; agregar $h_F \|\sigma_h \cdot n\|^2$ donde $\nu_h > \chi$. La elegida es la que más mejora sobre no tener término sin volverse inestable (la clasificación por faceta completa también mejora, menos): la complementariedad no es cuadrática en el error y sobreestima al crecer k (hasta ~ 50), el flujo donde $\nu_h > \chi$ sobreestima 10^2–10^7, y la clasificación por signo de $\sigma_h \cdot n$ es ruidosa cerca de la transición. El término de contacto sigue al error de borde en la zona de contacto: su cociente está entre 0.97 y 2.2.

Efectividad observada. Contra la norma del Teorema 3.9, $E_s^2 = \|\sigma - \sigma_h\|^2 + \|\nabla_h(u - \nu_h)\|^2 + \sum_{F \text{ int}} h_F^{-1} \|[\![\nu_h]\!]\|_F^2 + \sum_{F \subset \Gamma_D \cup \text{contacto}} h_F^{-1} \|u - \nu_h\|_F^2$ (el término de borde solo donde la traza de u está prescrita), última década de N, $k = 0, \ldots, 3$:

ejemplo	η / E_s adaptativo	η / E_s uniforme	$\tilde{\eta} / E$ adaptativo
transición en vértice, $f \in \mathrm{P}_0$	0.67–1.03	0.64–0.73	0.31–0.75
la misma u sin contacto	0.67–1.03	0.64–0.73	–
transición dentro de faceta, $f \in \mathrm{P}_0$	0.67–1.02	0.47–0.83	0.31–0.73
la misma u sin contacto	0.68–1.03	0.63–0.76	–
Bartels §7.2, $f \notin \mathrm{P}_k$	0.20–0.32	0.35–0.73	0.08–0.17

"Sin contacto" es el problema lineal con la misma u y Dirichlet en todo $\partial\Omega$ (`linear_check.jl` en `studies/estimators/`). Dos cuestiones quedan abiertas:

- *Transición dentro de una faceta.* Con refinamiento uniforme la efectividad baja y oscila también sin contacto (por nivel, 0.49–0.76 frente a 0.64–0.73 con la transición en un vértice): parte de la pérdida viene de que la singularidad cae dentro de un elemento, no del contacto. Con $k \geq 1$ Signorini pierde además un 10–30 % respecto del problema lineal (por ejemplo, $k = 3$: 0.41–0.50 frente a 0.49–0.67); esa parte es propia del contacto y ninguna de las variantes probadas la capta. Dónde se localiza ese error no está determinado. Con refinamiento adaptativo Signorini y el problema lineal coinciden para $k \leq 2$; con $k = 3$ Signorini baja hasta 0.67 (el lineal, hasta 0.77).
- $f \notin \mathrm{P}_k$. La efectividad baja en las mallas adaptativas y con $k = 0$, pero no con refinamiento uniforme y $k \geq 2$ (0.71–0.73 en Bartels §7.2). Es compatible con el Teorema 3.9: en ese ejemplo $\delta \approx 0.93$–0.99 (medido en las corridas guiadas por $\tilde{\eta}$), y la constante $1/(1-\delta)$ es grande. Con $k = 0$ la oscilación $h_K \|f - \Pi_k f\|_K$ tiene el tamaño del error ($\approx 1.1\, E_s$); con $k \geq 1$ en adaptativo es 2–4 veces mayor, así que no explica por sí sola lo que falta. La causa no está establecida.

6. Superconvergencia en orden bajo ($\mathrm{BDM}_1 \times \mathrm{P}_0$)

El paper no excluye $p = 1$: dice que para $p = 1$ se gana *un* orden en vez de dos, salvo si $f \in V_h^{p-1}$ (estimaciones (2.9) y (2.15) y su observación posterior; §4.1 con $f \notin \mathrm{P}_0$ frente a §4.2 con $f \equiv 0$). El motivo está en la cota (2.11):

$$\|u - \nu_h\|_K \leq \tfrac{h_K}{\pi} \big(\|q - q_h\|_K + \|\nabla(u - Q_K^{p+1} u)\|_K \big) + \|u_h - Q_K^{p-1} u\|_K + \|u - Q_K^{p+1} u\|_K .$$

Todos los términos son $O(h^{p+2})$ salvo la supercercanía $\|u_h - Q_h^{p-1} u\|$, que se obtiene por dualidad (Stenberg [3]; Ω convexo):

$$\|Q_h^{p-1} u - u_h\| \;\lesssim\; h\, \|q - q_h\| + h^{\min(p,2)}\, \|\operatorname{div}(q - q_h)\|, \qquad \operatorname{div}(q - q_h) = f - Q_h^{p-1} f .$$

El segundo término viene de $(\operatorname{div}(q - q_h), \varphi - Q_h^{p-1}\varphi)$ con $\|\varphi - Q_h^{p-1}\varphi\| \lesssim h^{\min(p,2)} |\varphi|_2$:

- $p \geq 2$: $h^2 \cdot O(h^p) = O(h^{p+2})$, es decir, se ganan dos órdenes.
- $p = 1$, $f \notin \mathrm{P}_0$: $h \cdot O(h) = O(h^2)$, es decir, se gana un orden. Es el caso de §4.1 del paper.
- $p = 1$, $f \in \mathrm{P}_0$: $\operatorname{div} q_h = f$ exactamente, el término desaparece y queda $h\,\|q - q_h\| = O(h^3)$, es decir, se ganan dos órdenes.

En el benchmark de los tests $f = -2$ es constante, así que $\operatorname{div} \sigma_h = -f$ exactamente (el test lo verifica) y $k = 0$ cae en el tercer caso. Para comprobarlo, se repitió el cálculo cambiando el término y^2 de la solución exacta por $y^2 \cos(\pi x)$, que no altera las condiciones en Γ_S y da $f = (\pi^2 y^2 - 2)\cos(\pi x) \notin \mathrm{P}_0$:

f	k	tasas $\|u - u_h\|$	tasas $\|u - \nu_h\|$
$-2 \in \mathrm{P}_0$	0	0.99, 1.00, 1.00	2.95, 2.97, 2.99
$(\pi^2 y^2 - 2)\cos(\pi x) \notin \mathrm{P}_0$	0	0.98, 1.00, 1.00	2.39, 2.21, 2.11
$(\pi^2 y^2 - 2)\cos(\pi x) \notin \mathrm{P}_0$	1	1.94, 1.98, 2.00	4.01, 4.00, 4.00

Mallas $n = 8, \ldots, 64$ ($k = 0$) y $n = 4, \ldots, 32$ ($k = 1$). Con $f \notin \mathrm{P}_0$, $k = 0$ baja a orden 2 y $k \geq 1$ no cambia, tal como predice el paper. La teoría es para el problema lineal; para Signorini es una observación numérica en un caso favorable (solución suave y frontera libre sobre un vértice de la malla).

7. Ejecución

Desde la raíz del paquete:

```
julia --project=. -e 'using Pkg; Pkg.test()'                  # tests (~1 min)
julia --project=. studies/convergence/export_csv.jl           # convergencia
julia --project=. studies/aposteriori/estimator_study.jl      # η̃ vs problema lineal
julia --project=. studies/adaptivity/adaptive_study.jl        # adaptividad (--bench, --problem)
julia --project=. studies/references/reference_examples.jl    # ejemplos de [4, 5]
julia --project=. studies/estimators/compare_estimators.jl    # η vs η̃
julia --project=. studies/estimators/contact_terms.jl         # variantes del término de contacto
julia --project=. studies/estimators/linear_check.jl          # η sin contacto (misma u)
python3 studies/<estudio>/plot_*.py                           # -> results/pdf/0*_*/
```

El índice de los PDF está en `results/pdf/README.md`.

Referencias

[1] I. Muga, S. Rojas, P. Vega. An adaptive superconvergent mixed finite element method based on local residual minimization. *SIAM J. Numer. Anal.* 61(5):2084–2105, 2023.

[2] Q. Wang, J. Hu, G. Zhou. The mixed method with two Lagrange multiplier formulations for the Signorini problem. *J. Comput. Appl. Math.* 452:116115, 2024.

[3] R. Stenberg. Postprocessing schemes for some mixed finite elements. *RAIRO Modél. Math. Anal. Numér.* 25(1):151–167, 1991.

[4] T. Führer, N. Heuer, E. P. Stephan. On the DPG method for Signorini problems. arXiv:1609.00765, 2016.

[5] S. Bartels, T. Gudi, A. Kaltenbach. A priori and a posteriori error identities for the scalar Signorini problem. arXiv:2407.10912, 2024.